Zaimplementuj aplikację szacującą czas ukończenia półmaratonu dla zadanych danych

1. Umieść dane w Digital Ocean Spaces

2. Napisz notebook, który będzie Twoim pipelinem do trenowania modelu

    - czyta dane z Digital Ocean Spaces
    - czyści je
    - trenuje model (dobierz odpowiednie metryki [feature selection])
    - nowa wersja modelu jest zapisywana lokalnie i do Digital Ocean Spaces
3. Aplikacja

    - opakuj model w aplikację streamlit
    - wdróż (deploy) aplikację za pomocą Digital Ocean AppPlatform
    - wejściem jest pole tekstowe, w którym użytkownik się przedstawia, mówi o tym jaka jest jego płeć, wiek i czas na 5km
    - jeśli użytkownik podał za mało danych, wyświetl informację o tym jakich danych brakuje
    - za pomocą LLM (OpenAI) wyłuskaj potrzebne dane, potrzebne dla Twojego modelu do określenia, do słownika (dictionary lub JSON)
    - tę część podepnij do Langfuse, aby zbierać metryki o skuteczności działania LLM'a

Funkcje odpowiedzialne za komunikację z digital ocean i openai

Funkcje próbują wczytać klucze z pliku env, a w przypadku braku pokazują pole tekstowe do wprowadzenia danych. Dalej mamy też funkcję wysyłającą dane na serwer digital ocean.

Funkcje pomocnicze

Funkcje pomocnicze odpowiedzialne za przeprocesowanie datasetu do uczenia maszynowego oraz do konwersji czasu z formatu time na ilość sekund

Wczytanie danych z digital ocean

Wczytujemy wcześniej zapisane dane z digital ocean oraz wyświetlamy ilość wczytanych wierszy, by mieć pewność poprawności wczytania.

```
Pomyślnie wczytano dane. Liczba wierszy: 8950
```

```
Pomyślnie wczytano dane. Liczba wierszy: 13007
```

Wypełanianie brakujących danych

Rzutujemy poszczególne kolumny na dany typ i wypełniamy brakujące dane. Kolumny liczbowe wypełniamy zerami. Poszczególne odcinki czasowe zamieniamy z formatu time na ilość sekund w celu ułatwienia dalszej analizy

	Miejsce	Numer startowy	Imię	Nazwisko	Miasto	Kraj	Drużyna	Płeć	Mi
4586	4587	3584	DAWID	PALUSZCZAK	WROCŁAW	POL	TOWARZYSZE	M	
5857	5858	2035	MARCJANNA	BACIK	OSTRZESZÓW	POL	NaN	K	
4796	4797	4896	WOJCIECH	GOŁĘBIOWSKI	WROCŁAW	POL	NaN	M	
7783	7784	4285	PAULINA	UJMA	WYSOKA	POL	NaN	K	
4463	4464	4273	HONORATA	ULATOWSKA	SZCZODRE	POL	NaN	K	
6228	6229	5086	ELŻBIETA	KURIATA	KUKLICE	POL	NaN	K	
2202	2203	1424	ARTUR	ZYTKO	SIECHNICE	POL	NaN	M	
8808	0	5134	RADOSŁAW	SZEWC	NaN	NaN	NaN	M	
1864	1865	5189	JAN	LECHOWSKI	JELCZ-LASKOWICE	POL	KB HARCOWNIK JELCZ-LASKOWICE	M	
6291	6292	5474	MICHALINA	PIETRUSZEWSKA	KARWIANY	POL	NaN	K	

10 rows × 27 columns

	Miejsce	Numer startowy	Imię	Nazwisko	Miasto	Kraj	Drużyna	Płeć	P Miej
1521	1522	2142	BARTŁOMIEJ	ŚWIĘCKI	WROCŁAW	POL	TYMUŚKI	M	14
2730	2731	7754	OSKAR	GONTA	WROCŁAW	POL	AAT	M	24
765	766	274	ŁUKASZ	ZACHARA	KILIANÓW	POL	KLUB BIEGACZA KĄTY WROCŁAWSKIE	M	1
1265	1266	1748	ARTUR	SADŁOWSKI	SKOMIELNA BIAŁA	POL	TEAM KOJOT	M	11
5767	5768	4221	Anonimowy	ZAWODNIK	NaN	POL	ŚWIŃSKI BIEG	M	47
5458	5459	8286	ZUZANNA	GADKOWSKA	WSCHOWA	POL	NaN	K	9
616	617	666	PIOTR	CHOLEWSKI	WYSZKÓW	POL	KB WYSZKÓW	M	5
7380	7381	8305	AGNIESZKA	ZIENKIEWICZ	OSINY	POL	WIECZRNE BIEGANIE W OPOLU	K	16
11557	0	26572	JACEK	LIPCZYŃSKI	NaN	NaN	NaN	M	
8543	8544	3111	KACPER	MEDYGRAL	WROCŁAW	POL	#PLANBIEGANIE	M	63

10 rows × 27 columns

Wypełniamy brakujące wartości w danych demograficznych

Braki w danych demograficznych zostały uzupełnione wartościami typowymi dla tego zbioru (dominanta). Dzięki temu model klastrowania może przetworzyć wszystkie rekordy, zachowując spójność z profilem typowego uczestnika maratonu

Wypełnianie brakujących wartości w statystykach biegowych

W celu uzupełnienia braków w międzyczasach zastosowano interpolację liniową. Wybór tej metody podyktowany jest charakterystyką danych procesowych (bieg ciągły) – pozwala ona na oszacowanie brakujących wartości w oparciu o dynamikę tempa konkretnego zawodnika pomiędzy najbliższymi znanymi punktami pomiarowymi, co minimalizuje ryzyko wprowadzenia błędów do analizy stabilności biegu.

	Miejsce	Numer startowy	Imię	Nazwisko	Miasto	Kraj	Drużyna	Płeć	Płe Miejsc
2329	2330	9271	RADOSŁAW	ADAMSKI	ŁÓDŹ	POL	Brak	M	209
2173	2174	9798	MARCIN	DĄBROWSKI	WROCŁAW	POL	MATNER RUNNING TEAM	M	196
5532	5533	2163	JAKUB	KŁOSSOWSKI	WARSZAWA	POL	Brak	M	441
792	793	6380	ALEKSANDR	RASCHINSKIY	WARSZAWA	BLR	MIKKELLER RUNNING CLUB	M	73
8251	0	3470	MARCIN	DETNERSKI	Brak	Brak	Brak	M	
5565	5566	5948	IRENA	KUNICKA	BYSTRZYCA	POL	Brak	K	112
6901	6902	5172	GRZEGORZ	RODER	LEGNICA	POL	Brak	M	519
1703	1704	918	MARCIN	PIESZAK	WROCŁAW	POL	CAMPUS DOMASŁAWICE TEAM	M	156
6332	6333	7382	MARCIN	BLIMEL	DĄBRÓWKA	POL	Brak	M	489
6227	6228	4200	ANDRZEJ	KOWALSKI	WARSZAWA	POL	NAPRZÓD MŁOCINY	M	483

10 rows × 27 columns

	Miejsce	Numer startowy	Imię	Nazwisko	Miasto	Kraj	Drużyna	Płeć
10348	0	4194	MICHAŁ	BALCERZAK	Brak	Brak	Balcerzak Running Team	M
6947	6948	8529	DAMIAN	LOBA	POZNAŃ	POL	ŚWIERCZEWO RUN	M
1297	1298	5331	LESŁAW	LEŚNIAK	KIELCE ŚWIĘTOKRZYSKIE	POL	ZABIEGANI W KIELCACH	M
11233	0	8337	HYELYUN	KIM	Brak	Brak	Lg Energy Solution Wroław	K
12224	0	23790	DARIUSZ	RZEPA	Brak	Brak	Brak	M
12982	0	21521	DANIEL	ŁĄGIEWKA	Brak	Brak	Press Glass Sport And Support	M
12173	0	10289	KRZYSZTOF	ROJKIEWICZ	Brak	Brak	Brak	M
6843	6844	9840	MAŁGORZATA	SŁOMIŃSKA	STARGARD SZCZECIŃSKI	POL	BIEGUNKA	K
298	299	756	Anonimowy	ZAWODNIK	Brak	POL	1985	M
9001	9002	4462	ANNA	KORCZYŃSKA	LEGNICA	POL	BBL LEGNICA	K

10 rows × 27 columns

Ranking i obsługa miejsc

Dla kolumn określających pozycję zawodników (Open, Płeć oraz Międzyczasy) zastosowano metodę rankingu 'min' (Competition Ranking). Wybór ten podyktowany jest chęcią zachowania spójności z oficjalnymi zasadami sędziowania zawodów sportowych, gdzie zawodnicy z identycznym czasem zajmują tę samą pozycję, a kolejny numer miejsca jest odpowiednio przesunięty. W procesie modelowania cechy te zostały wyłączone z obliczeń (ignored features), aby uniknąć redundancji danych z kolumnami czasowymi, jednak zachowano je jako kluczowy kontekst dla modelu językowego (LLM) przy generowaniu opisów klastrów.

	Miejsce	Numer startowy	Imię	Nazwisko	Miasto	Kraj	Drużyna	Płeć	Płeć Miejsce
5803	6830	4310	TOMASZ	GULBIERZ	WROCŁAW	POL	Brak	M	5624
1169	1225	3901	PAWEŁ	MILEWSKI	WROCŁAW	POL	Brak	M	1152
6456	7681	5114	MIROSŁAW	HOŁDYŃSKI	KĄTY WROCŁAWSKIE	POL	WKB META	M	6149
6588	7884	8159	ZBIGNIEW	HOFFMANN	LESZNO	POL	Brak	M	6284
8186	10326	8398	KAROL	ORZECHOWSKI	KOBYLICE	POL	AKS BUKOWE	M	7727
10808	11021	23268	EWA	FUCHS	Brak	Brak	Brak	K	2965
7409	9115	9951	MICHAŁ	ZIEGLER	WYSOKA	POL	Brak	M	7046
902	944	2564	MARCIN	BŁASZCZAK	PSZCZEW	POL	Brak	M	895
6191	7297	4296	MARCIN	JURCZENKO	KRAKÓW	POL	ITMBW KRAKÓW	M	5902
5244	6106	10852	ŁUKASZ	JABŁOŃSKI	WROCŁAW	POL	CHŁOSTA	M	5153

10 rows × 27 columns

Walidacja Schematu Danych (Pandera)

Po zakończeniu procesu preprocessingu i inżynierii cech, dane zostają poddane rygorystycznej walidacji schematu przy użyciu biblioteki Pandera. Cel tego kroku:

```
Gwarancja spójności typów: Upewnienie się, że kolumny numeryczne (np.
Tempo, Czas) są faktycznie liczbami, a kategoryczne (np. Płeć) zawierają
tylko dozwolone wartości ("M", "K").
Zabezpieczenie modelu ML: Model klastrujący oczekuje konkretnego zestawu
wejściowego. Walidacja schematu zapobiega błędom w fazie predykcji, które
mogłyby wyniknąć ze zmiany formatu danych wejściowych.
Obsługa braków: Jawne zdefiniowanie parametrów nullable=True pozwala na
kontrolowany nadzór nad rekordami, które posiadają niepełne informacje.
```

Jest to ostatnia barierka ochronna przed wdrożeniem aplikacji na produkcję w DigitalOcean, gwarantująca, że skrypt nie przerwie pracy z powodu niespodziewanej zmiany w strukturze plików CSV.

```
Dane maraton23 są poprawne

Dane maraton24 są poprawne
```

Inżynieria Cech i Preprocessing Końcowy

Funkcja preprocessing_maraton odpowiada za ostateczne przygotowanie danych przed walidacją schematu i modelowaniem. Kluczowe operacje to:

```
Normalizacja typów danych: Konwersja kolumn kategorycznych na typ tekstowy
oraz rygorystyczne wymuszenie typów numerycznych dla parametrów czasowych
(eliminacja błędów formatowania CSV).
Wyliczanie cech pochodnych (Feature Engineering):
    Tempo: Obliczenie średniego tempa biegu na podstawie czasu całkowitego
i dystansu maratońskiego (42.195 km).
    Tempo_Stabilnosc: Wyznaczenie odchylenia standardowego z międzyczasów
na poszczególnych odcinkach. Jest to kluczowa cecha określająca strategię
biegu zawodnika (tzw. pacing), pozwalająca modelowi ML na odróżnienie
biegaczy stabilnych od tych, którzy drastycznie zwalniają w drugiej
połowie dystansu.
```

	Miejsce	Numer startowy	Imię	Nazwisko	Miasto	Kraj	Drużyna	Płeć	Płeć Miejsce	K
1189	1248	19	KAROLINA	STAWARZ	OLEŚNICA	POL	KARUN	K	78	
378	397	225	MILENA	BATOR	ZAWONIA	POL	OŚ RACING TEAM	K	20	
215	227	380	OLHA	PUHACHOVA	KYIV	UKR	TS REGLE SZKLARSKA POREBA	K	7	
20	23	387	NATALIJA	SEMENOVYCH	KIJÓW	UKR	Brak	K	1	
397	416	403	AGATA	MAJ	Brak	NOR	Brak	K	22	
...	...	...	...	...	...	...	...	...	...	
10642	11540	85668	JANUSZ	DALEK	Brak	Brak	Brak	M	8326	
10638	11508	86230	JERZY	CZYNIEWSKI	Brak	Brak	Brak	M	8307	
9096	11482	9148	STANISŁAW	BEDNARSKI	STRZELIN	POL	Brak	M	8295	
11974	11482	10897	MARIAN	PAWLACZYK	Brak	Brak	Wkb Piast Wrocław	M	8295	
12484	11482	23859	JÓZEF	SZCZĘŚNIAK	Brak	Brak	Brak	M	8295	

13007 rows × 27 columns

Egzekucja Walidacji i Raportowanie Błędów

Poniższy blok kodu uruchamia proces weryfikacji danych dla obu roczników maratonu. Wykorzystanie trybu Lazy Validation pozwala na przechwycenie wszystkich niezgodności ze schematem jednocześnie. W przypadku wykrycia błędów (np. niewłaściwych typów danych lub naruszenia reguł biznesowych), generowany jest szczegółowy raport failure_cases, który wskazuje precyzyjną lokalizację problematycznych rekordów.

```
Walidacja nie powiodła się. Znalezione błędy:
  column  failure_case index   schema_context             check check_number
0   None  Rok_maratonu  None  DataFrameSchema  column_in_schema         None
```

Anonimizacja Danych Wrażliwych (Faker)

W celu ochrony prywatności uczestników maratonu oraz spełnienia standardów bezpieczeństwa danych (zgodność z RODO), zastosowano proces anonimizacji. Dlaczego Faker?

```
Eliminacja danych wrażliwych: Prawdziwe imiona i nazwiska biegaczy zostały
zastąpione danymi syntetycznymi wygenerowanymi przez bibliotekę Faker.
Zachowanie realizmu: W przeciwieństwie do zwykłego usuwania kolumn, Faker
pozwala zachować strukturę danych (np. rozróżnienie płci na podstawie
imion), co jest istotne dla modelu językowego (LLM) podczas generowania
opisów klastrów.
Bezpieczeństwo w chmurze: Dzięki temu procesowi, zbiory danych
przechowywane w DigitalOcean Spaces oraz przesyłane do OpenAI API nie
zawierają żadnych informacji pozwalających na identyfikację konkretnych
osób fizycznych.
```

	Miejsce	Numer startowy	Imię	Nazwisko	Miasto	Kraj	Drużyna	Płeć	Płeć Miejsce	K
6551	7207	100	Rozalia	Białasik	Mława	POL	Ciepłuch-Horbacz S.A.	K	1748	
1029	1066	117	Jędrzej	Rejniak	Lubliniec	POL	Fundacja Marko	K	73	
8138	8939	119	Kazimierz	Wawrzonek	Słupsk	POL	FPUH Zontek	K	2607	
6523	7177	121	Aleksander	Kunert	Wyszków	POL	Joszko Sp.k.	K	1732	
8215	7292	143	Alex	Pawlonka	Nowy Dwór Mazowiecki	Brak	Grupa Szatko	K	1791	
...	...	...	...	...	...	...	...	...	...	
6448	7092	8535	Natasza	Gołoś	Jawor	POL	Senator i syn s.c.	M	5398	
7229	7971	8703	Emil	Wyskiel	Kościerzyna	POL	Spółdzielnia Maszota	M	5855	
2188	2314	8965	Fabian	Kwapisiewicz	Warszawa	POL	Gabinety Boguś	M	2092	
8136	8937	2797	Maksymilian	Wacławiak	Turek	POL	Gabinety Trzyna Sp.k.	M	6331	
7771	8560	7708	Jan	Woronko	Sieradz	POL	Preuss i syn s.c.	M	6129	

8950 rows × 27 columns

	Miejsce	Numer startowy	Imię	Nazwisko	Miasto	Kraj	Drużyna	Płeć	Płe Miejsc
1189	1248	19	Sandra	Więcławek	Grudziądz	POL	Stowarzyszenie Grzelec	K	7
378	397	225	Anita	Frycz	Żagań	POL	Kluczek Sp. z o.o. Sp.k.	K	2
215	227	380	Malwina	Starościak	Kłodzko	UKR	PPUH Romaniak Sp.k.	K	
20	23	387	Urszula	Nyc	Wałcz	UKR	FPUH Niedośpiał-Kawala S.A.	K	
397	416	403	Maurycy	Doktor	Gliwice	NOR	Grupa Majdak i syn s.c.	K	2
...	...	...	...	...	...	...	...	...	
10642	11540	85668	Przemysław	Kopik	Gorzów Wielkopolski	Brak	PPUH Rolek Sp.j.	M	832
10638	11508	86230	Marek	Noras	Chełm	Brak	Spółdzielnia Piwowarek i syn s.c.	M	830
9096	11482	9148	Stanisław	Filus	Jawor	POL	FPUH Prokopiak Sp.j.	M	829
11974	11482	10897	Piotr	Wojewodzic	Myszków	Brak	Fundacja Kuba-Martynowicz S.A.	M	829
12484	11482	23859	Ksawery	Paśnik	Siemianowice Śląskie	Brak	Stowarzyszenie Herba S.A.	M	829

13007 rows × 27 columns

	Miejsce	Numer startowy	Imię	Nazwisko	Miasto	Kraj	Drużyna	Płeć	Płe Miejsc
0	7207	100	Rozalia	Białasik	Mława	POL	Ciepłuch-Horbacz S.A.	K	1748
1	1066	117	Jędrzej	Rejniak	Lubliniec	POL	Fundacja Marko	K	73
2	8939	119	Kazimierz	Wawrzonek	Słupsk	POL	FPUH Zontek	K	2607
3	7177	121	Aleksander	Kunert	Wyszków	POL	Joszko Sp.k.	K	1732
4	7292	143	Alex	Pawlonka	Nowy Dwór Mazowiecki	Brak	Grupa Szatko	K	1791
...	...	...	...	...	...	...	...	...	.
21952	11540	85668	Przemysław	Kopik	Gorzów Wielkopolski	Brak	PPUH Rolek Sp.j.	M	8326
21953	11508	86230	Marek	Noras	Chełm	Brak	Spółdzielnia Piwowarek i syn s.c.	M	8307
21954	11482	9148	Stanisław	Filus	Jawor	POL	FPUH Prokopiak Sp.j.	M	8295
21955	11482	10897	Piotr	Wojewodzic	Myszków	Brak	Fundacja Kuba-Martynowicz S.A.	M	8295
21956	11482	23859	Ksawery	Paśnik	Siemianowice Śląskie	Brak	Stowarzyszenie Herba S.A.	M	8295

21957 rows × 28 columns

Inżynieria Cech i Przygotowanie Danych (Feature Engineering)

Funkcja prepare_marathon_data pełni kluczową rolę w transformacji surowych danych maratońskich na format wejściowy dla algorytmów uczenia maszynowego. Proces ten obejmuje trzy kluczowe etapy:

```
Ekstrakcja Cech Demograficznych (Parsing):
    Przetworzenie kolumny „Kategoria wiekowa” w celu wyodrębnienia
numerycznej grupy wiekowej oraz zamiana płci na format One-Hot Encoding
(Plec_K, Plec_M). Pozwala to modelowi na matematyczną interpretację różnic
biologicznych i wiekowych między biegaczami.
Selekcja Cech (Feature Selection):
    Wybór unikalnego zestawu zmiennych łączących dynamikę biegu
(międzyczasy i czas końcowy) z danymi demograficznymi. Dzięki temu
klastrowanie odbywa się w wielowymiarowej przestrzeni uwzględniającej
```

```
zarówno tempo, jak i profil biegacza.
Standaryzacja (StandardScaler):
    Kluczowy krok dla algorytmów opartych na odległościach (np. K-Means).
Standaryzacja sprowadza cechy o różnych jednostkach (sekundy vs wiek) do
wspólnej skali o średniej 0 i odchyleniu 1, co zapobiega dominacji modelu
przez zmienne o większych wartościach liczbowych.
```

	Miejsce	Numer startowy	Imię	Nazwisko	Miasto	Kraj	Drużyna	Płeć	Płeć Miejsce	Kat w
13302	1368	2704	Aleks	Dulik	Białogard	POL	Fundacja Chaba S.A.	M	1277	
19528	6051	7864	Miłosz	Chojna	Kielce	POL	Grupa Roda	M	5111	
9530	10146	10700	Norbert	Kościk	Białystok	POL	Dziczek s.c.	K	2512	
7335	60	6909	Patryk	Dering	Bielawa	AUT	PPUH Mila Sp.j.	M	57	
13689	6308	5832	Krzysztof	Uliasz	Koszalin	POL	Stowarzyszenie Chomiuk-Miszta Sp. z o.o. Sp.k.	M	5294	
9806	3407	85332	Daniel	Powała	Sochaczew	Brak	Fundacja Sieczko	K	363	
8913	6901	2566	Agnieszka	Dzienisz	Będzin	POL	Ryczko-Cebulak Sp. z o.o. Sp.k.	M	5306	
18777	11722	4389	Klara	Kempny	Sieradz	POL	Stowarzyszenie Pawliczak s.c.	M	8420	
15606	1041	3748	Igor	Kozień	Kraków	POL	Grupa Wyderka	M	984	
2920	6776	3047	Karina	Wojnicz	Oświęcim	POL	Hallmann-Pawela Sp.j.	M	5224	

10 rows × 31 columns

Upload to digital ocean

Gotowy zbiór treningowy wysyłamy do serwera digital ocean

```
Plik halfmarathon_wroclaw_final.csv wysłany bezpośrednio do maraton
```

Trenowanie i budowa modelu treningowego

Najważniejsza funkcja do budowy modelu treningowego. Można w niej wybrać ilość grup klastrów, na które funkcja będzie starać się podzielić. Można też wybrać, czy zastosować normalizację i transformację.

1. Z-Score Normalization – aby sprowadzić cechy o różnych jednostkach (wiek, sekundy, punkty stabilności) do wspólnej skali, zapewniając każdemu z nich równy wpływ na ostateczny wynik grupowania.
2. Quantile Transformation – w celu zniwelowania asymetrii rozkładów (szczególnie w czasach i tempie) i zbliżenia ich do rozkładu normalnego, co poprawia stabilność algorytmów klastrujących.

Wybór optymalnego modelu klastrowania został oparty na analizie porównawczej następujących wskaźników:

```
1) Precision: Miara wiarygodności przypisania – minimalizuje ryzyko
błędnego zakwalifikowania biegacza do niewłaściwej grupy profilowej.
2) Recall: Miara kompletności – gwarantuje, że model potrafi
zidentyfikować większość reprezentantów danej charakterystyki biegowej.
3) F1-Score: Kluczowy wskaźnik optymalizujący kompromis między precyzją a
czułością, zapewniający stabilność modelu.
4) Min_Pct: Parametr kontrolny dbający o odpowiednią liczebność grup,
zapobiegający nadmiernej fragmentacji danych.
5) Homogeneity & Completeness: Pozwalają ocenić, na ile klastry
odzwierciedlają naturalne podziały (np. płeć, wiek), mimo że model nie
widział tych etykiet podczas treningu.
6) Cluster Size (Min/Max/Pct): Parametry te gwarantują użyteczność
biznesową modelu – eliminujemy rozwiązania, które tworzą zbyt małe
(nieistotne statystycznie) lub zbyt duże (mało precyzyjne) grupy.
7) n_clusters: Kluczowy parametr kontrolujący ziarnistość podziału
społeczności maratońskiej.
```

Porównanie i selekcja modeli klastrujących

W projekcie przetestowano cztery fundamentalnie różne podejścia do segmentacji danych, aby znaleźć najbardziej stabilny podział społeczności maratońskiej:

```
K-Means (Podział oparty na centrach):
    Dlaczego: Klasyk i standard w klastrowaniu. Szybki i efektywny, gdy
grupy mają kształt zbliżony do kulistego. Idealny do wyznaczenia wyraźnych
centrów profili biegaczy (np. „typowy amator”).
BIRCH (Podejście hierarchiczne i skalowalne):
    Dlaczego: Świetnie radzi sobie z dużymi zbiorami danych (ponad 21 tys.
rekordów). Buduje drzewo cech, co pozwala na szybszą analizę bez
konieczności trzymania wszystkich danych w pamięci RAM. Jest mniej
wrażliwy na szum niż K-Means.
Affinity Propagation (AP - Przekazywanie podobieństwa):
    Dlaczego: W przeciwieństwie do K-Means, ten model nie wymaga
wcześniejszego podania liczby klastrów. Sam wybiera „reprezentantów”
(egzemplarze) grup, co pozwala odkryć naturalną strukturę danych, której
mogliśmy nie przewidzieć.
MeanShift (Przesunięcie ku gęstości):
```

```
    Dlaczego: Algorytm poszukuje obszarów o największym zagęszczeniu
biegaczy w przestrzeni cech. Jest bardzo dobry w ignorowaniu outlierów
(np. osób o absurdalnych czasach) i skupianiu się na realnych trendach
wewnątrz grup.

Uruchamiam eksperyment: KMEANS_k5_n_False_t_False
Uruchamiam eksperyment: KMEANS_k10_n_False_t_False
Uruchamiam eksperyment: BIRCH_k5_n_False_t_False
Uruchamiam eksperyment: BIRCH_k10_n_False_t_False
Uruchamiam eksperyment: AP_k5_n_False_t_False
Uruchamiam eksperyment: AP_k10_n_False_t_False
Uruchamiam eksperyment: MEANSHIFT_k5_n_False_t_False
Uruchamiam eksperyment: MEANSHIFT_k10_n_False_t_False
Uruchamiam eksperyment: KMEANS_k5_n_True_t_False
Uruchamiam eksperyment: KMEANS_k10_n_True_t_False
Uruchamiam eksperyment: BIRCH_k5_n_True_t_False
Uruchamiam eksperyment: BIRCH_k10_n_True_t_False
Uruchamiam eksperyment: AP_k5_n_True_t_False
Uruchamiam eksperyment: AP_k10_n_True_t_False
Uruchamiam eksperyment: MEANSHIFT_k5_n_True_t_False
Uruchamiam eksperyment: MEANSHIFT_k10_n_True_t_False
Uruchamiam eksperyment: KMEANS_k5_n_False_t_True
Uruchamiam eksperyment: KMEANS_k10_n_False_t_True
Uruchamiam eksperyment: BIRCH_k5_n_False_t_True
Uruchamiam eksperyment: BIRCH_k10_n_False_t_True
Uruchamiam eksperyment: AP_k5_n_False_t_True
Uruchamiam eksperyment: AP_k10_n_False_t_True
Uruchamiam eksperyment: MEANSHIFT_k5_n_False_t_True
Uruchamiam eksperyment: MEANSHIFT_k10_n_False_t_True
Uruchamiam eksperyment: KMEANS_k5_n_True_t_True
Uruchamiam eksperyment: KMEANS_k10_n_True_t_True
Uruchamiam eksperyment: BIRCH_k5_n_True_t_True
Uruchamiam eksperyment: BIRCH_k10_n_True_t_True
Uruchamiam eksperyment: AP_k5_n_True_t_True
Uruchamiam eksperyment: AP_k10_n_True_t_True
Uruchamiam eksperyment: MEANSHIFT_k5_n_True_t_True
Uruchamiam eksperyment: MEANSHIFT_k10_n_True_t_True
```

Analiza Porównawcza i Wybór Modelu

W celu wyłonienia optymalnego algorytmu, wyniki wszystkich modeli zostały zestawione w tabeli zbiorczej. Kluczowymi wskaźnikami, na których oparto decyzję o wyborze modelu produkcyjnego, są:

```
Silhouette Score (Podświetlony):
    Co oznacza: Mierzy, jak blisko swojego klastra znajduje się każdy
punkt w porównaniu do klastrów sąsiednich.
    Interpretacja: Wysoka wartość Silhouette wskazuje, że klastry są
dobrze odseparowane i nie nakładają się na siebie. Jest to kluczowe dla
LLM – wyraźne różnice w danych wejściowych pozwalają na wygenerowanie
unikalnych i trafnych opisów dla każdej grupy.
Homogeneity (Podświetlony):
    Co oznacza: Sprawdza, czy klastry są spójne pod kątem cech
kategorycznych (np. płeć, kategorie wiekowe).
    Interpretacja: Wysoka jednorodność oznacza, że podział wygenerowany
przez algorytm "pokrywa się" z naturalnymi podziałami społecznymi
```

```
biegaczy. Dzięki temu nazwy klastrów (np. "Szybkie Kobiety") są osadzone w
rzeczywistości, a nie są jedynie abstrakcyjnym zbiorem liczb.
```

Wniosek: Model z najwyższymi wartościami w tych polach zapewnia najlepszy balans między matematyczną poprawnością a możliwością interpretacji wyników przez człowieka.

```
--- Tabela Porównawcza Metryk ---
```

10 entries per page Search:

model	Silhouette	Calinski-Harabasz	Davies-Bouldin	Hor
KMEANS_k5_n_False_t_False	0.426	5440.113	0.705	
KMEANS_k10_n_False_t_False	0.300	3933.794	1.018	
BIRCH_k5_n_False_t_False	0.359	4766.684	0.776	
BIRCH_k10_n_False_t_False	0.290	3865.661	0.905	
AP_k5_n_False_t_False	0.273	2827.904	1.010	
AP_k10_n_False_t_False	0.273	2827.904	1.010	
MEANSHIFT_k5_n_False_t_False	0.475	2349.375	0.677	
MEANSHIFT_k10_n_False_t_False	0.475	2349.375	0.677	
KMEANS_k5_n_True_t_False	0.245	845.768	1.417	
KMEANS_k10_n_True_t_False	0.206	558.071	1.591	

Showing 1 to 10 of 32 entries « ‹ 1 2 3 4 › »

Selekcja Modelu Produkcyjnego (Model Selection Logic)

Proces wyboru ostatecznego modelu nie opiera się wyłącznie na najwyższych metrykach, ale przede wszystkim na kryteriach stabilności operacyjnej. Zastosowano wielostopniowy filtr bezpieczeństwa:

```
Kompatybilność API: Ograniczono wybór do modeli K-Means i BIRCH, które
natywnie wspierają metodę .predict(). Jest to niezbędne do poprawnego
działania aplikacji w trybie "na żywo" na DigitalOcean.
Reprezentatywność grup (Min_Cluster_Pct >= 2%): Wyeliminowano modele
tworzące zbyt małe klastry (tzw. outliery), które nie niosą wartości
statystycznej i mogłyby mylić model językowy LLM.
Zdolność do uogólniania (Max_Cluster_Size < 80%): Odrzucono modele, które
"idą na łatwiznę", wrzucając większość biegaczy do jednego ogromnego
worka. Dążymy do realnego podziału społeczności.
Złożoność (n_clusters <= 15): Ustalono limit grup, aby zachować czytelność
raportu i zmieścić się w limitach kontekstu (Context Window) API OpenAI.
```

Ostateczny wybór: Spośród modeli spełniających powyższe rygory, wybrano ten o najwyższym wskaźniku Homogeneity, co gwarantuje, że podział matematyczny najlepiej pokrywa się z rzeczywistymi cechami biegaczy.

```
Najlepszy model do APLIKACJI: BIRCH_k10_n_False_t_True
```

Zapis wybranego modelu

Na koniec analizy zapisujemy model lokalnie i w digital ocean.

```
Transformation Pipeline and Model Successfully Saved
Sukces! Model zapisany lokalnie pod kluczem: BIRCH_k10_n_False_t_True
Model e:\od_zera_do_ai\pyt\zad9_1\data\model_maraton.pkl został wysłany do Space: maraton
jako model_maraton.pkl
```